

Sistem Inspeksi Cacat pada Permukaan Kayu menggunakan Model Deteksi Obyek YOLOv5

FITYANUL AKHYAR, LEDYA NOVAMIZANTI, TITA RIANIARNI

Teknik Telekomunikasi, Fakultas Teknik Elektro, Telkom University, Indonesia
Email : ledyaldn@telkomuniversity.ac.id

Received 15 Agustus 2022 | *Revised* 29 September 2022 | *Accepted* 19 Oktober 2022

ABSTRAK

Permukaan kayu mengalami berbagai serangan serangga dan jamur, sehingga dapat menyebabkan cacat seperti pembusukan pada kayu yang berpengaruh terhadap kualitas dan harga jual kayu tersebut. Pengujian secara lapangan dengan penglihatan manusia menjadi kurang efektif, karena menghasilkan penilaian yang subjektif dan memerlukan waktu yang lama. Penelitian ini mengusulkan sistem deteksi cacat pada permukaan kayu pinus dan kayu karet menggunakan Convolutional Neural Network (CNN) dengan model YOLOv5. Pengujian sistem dilakukan menggunakan beberapa model dari YOLOv5, serta dua teknik image enhancement, yaitu edge filter dan Real ESRGAN. Hasil mAP terbaik sebesar 94,3% dengan kecepatan 125 FPS pada dataset kayu pinus menggunakan model YOLOv5s tanpa penambahan image enhancement. Sedangkan pada dataset kayu karet yang memiliki jenis cacat yang lebih kompleks, hasil mAP terbaik adalah sebesar 94,7% dengan kecepatan 139 FPS menggunakan model YOLOv5s-Transformer dengan penambahan image enhancement Real ESRGAN.

Kata kunci: deteksi, kayu, Convolutional Neural Network (CNN), YOLO

ABSTRACT

Wood surface is subject to various insect and fungal attacks, which can cause defects such as wood rot. This condition affects the quality as well as the selling price of the wood. Field testing with human eyesight becomes less effective because it produces a subjective assessment and time consuming. This study proposes a defect detection system on the surface of pine wood and rubber wood using the Convolutional Neural Network (CNN) with the YOLOv5 model. System testing was carried out using several models from YOLOv5 and two image enhancement techniques, namely edge filter and Real ESRGAN. The best mAP results were 94.3%, with a speed of 125 FPS on the pine wood dataset using the YOLOv5s model without adding image enhancement. While on the rubber wood dataset with more complex defect problem, the best mAP results were 94.7% with a speed of 139 FPS using the YOLOv5s-Transformer model with the addition of image enhancement Real ESRGAN.

Keywords: detection, wood, Convolutional Neural Network (CNN), YOLO

1. PENDAHULUAN

Industri kayu di Indonesia kini menunjukkan perkembangan yang positif dari tahun ke tahun **(Mutaqin, dkk, 2022)**. Namun, pada pengolahan kayu tersebut masih terdapat banyak cacat pada permukaan kayu. Hal ini dapat mempengaruhi kualitas serta harga jual dari kayu itu sendiri. Kualitas kayu yang diproduksi menjadi suatu hal yang sangat penting untuk melihat tingkat keawetan dari suatu kayu. Saat ini, banyak pabrik kayu olahan masih mempekerjakan manusia untuk melakukan inspeksi atau pengecekan cacat kayu **(Kumadi, dkk, 2020)**. Inspeksi manusia bersifat subjektif dan seringkali memiliki efisiensi dan akurasi yang sangat rendah dan juga memakan waktu yang lebih lama.

Dalam dekade terakhir, visi mesin telah banyak diperhatikan dan diterapkan pada pemeriksaan cacat kayu dengan keunggulan biaya rendah, kecepatan deteksi, dan akurasi tinggi. Untuk mendeteksi cacat kayu, pada awalnya, peneliti merancang dan mengekstrak beberapa fitur dari gambar kayu, termasuk warna, tekstur, dan *gray level co-occurrence matrix* (GLCM) untuk merepresentasikan cacat. Penelitian **(Bayu, dkk, 2015)** mengusulkan sistem deteksi ada tidaknya cacat pada kayu menggunakan ekstraksi ciri statistik dan metode klasifikasi *k-Nearest Neighbor*. Penelitian tersebut hanya menghasilkan akurasi sebesar 79,32%. Adapula penelitian **(Wananda, dkk, 2018)** mendeteksi kayu dalam kondisi normal dan rusak menggunakan metode SUSAN *Edge Detector* dan ekstraksi ciri statistik orde kedua. Penelitian tersebut menghasilkan akurasi sebesar 90,67% dengan waktu komputasi 2,5 detik. Kemudian, sistem dilatih menggunakan beberapa pengklasifikasi, seperti *clustering*, *Support Vector Machine* (SVM), algoritma genetika, dan jaringan saraf untuk membedakan cacat dari daerah normal **(Tu, dkk, 2021)**. Pada **(Li, dkk, 2017)**, metode klasifikasi cacat berdasarkan analisis diskriminan linier (LDA) telah diusulkan untuk klasifikasi cacat. Selanjutnya, penelitian **(Li, dkk, 2019)** mengusulkan algoritma klasifikasi berbasis *local binary pattern* (LBP) dan pola *local binary differential excitation* untuk klasifikasi retakan pada permukaan lapisan kayu. Dalam teknik ini, ekstraksi fitur dan pelatihan pengklasifikasi dirancang secara terpisah. Fitur-fitur ini mudah terpengaruh oleh *noise* **(Zhang, dkk, 2019)**. Selain itu, kinerja teknik ini sangat tergantung pada ekstraksi dan representasi sifat cacat **(Ren, dkk, 2017)**, yang selanjutnya bergantung pada keahlian manusia. Oleh karena itu, sulit untuk merancang metode yang efisien untuk mencapai representasi fitur yang optimal dan deteksi cacat pada permukaan.


Penggunaan teknologi *deep learning* dengan model *Convolutional Neural Network* (CNN) telah berhasil digunakan di berbagai bidang karena kemampuannya yang signifikan dalam ekstraksi fitur dan klasifikasi gambar, dan deteksi objek **(Abdulfattah, dkk, 2021)**. Baru-baru ini, banyak tim peneliti ilmiah telah mengusulkan metode berbasis CNN untuk mendeteksi cacat pada gambar kayu. Penelitian **(Hu, dkk, 2019)**, menyelidiki variasi dalam strategi *deep learning* berbasis ResNet18 untuk klasifikasi gambar kayu. Pada **(Ren, dkk, 2017)**, pengklasifikasi pada fitur *patches* gambar telah diusulkan, dan kemudian, *pixel-wise prediction* dapat diperoleh oleh pengklasifikasi terlatih. Penelitian **(Jung, dkk, 2018)** mengusulkan metode deteksi cacat pada kayu dengan permukaan bertekstur acak telah diusulkan, yang menggunakan tiga arsitektur CNN yang berbeda. Namun, ketiga penelitian tersebut mengalami akurasi yang rendah karena tidak dapat beradaptasi dengan perubahan multi-skala dalam tampilan objek. Pada **(Urbonas, dkk, 2019)**, RCNN yang lebih cepat telah digunakan untuk identifikasi cacat pada permukaan *veneer* kayu. RCNN yang menghasilkan sepuluh kali mAP lebih tinggi, namun enam kali lebih lambat dari *You Only Look Once* (YOLO) **(Redmon, dkk, 2016)**. Meskipun banyak penelitian tentang metode deteksi cacat berbasis CNN, pengenalan cacat permukaan kayu masih menghadapi beberapa tantangan, termasuk *trade-off* antara akurasi dan kecepatan. Deteksi cacat permukaan kayu adalah masalah

deteksi objek, yang dapat diselesaikan dengan algoritma deteksi objek. YOLO merupakan salah satu algoritma yang handal dalam mendeteksi objek **(Lathifah, dkk, 2020)**. Penelitian **(Tu, dkk, 2021)** mengusulkan detektor cacat pada permukaan kayu menggunakan YOLOv3 berbasis Gaussian-*complete* IoU (GC-YOLOv3). Hasil mAP diperoleh sebesar 92.29% dan kecepatan 39.81 FPS pada dataset kayu pinus. Sedangkan pada dataset kayu karet, hasil mAP diperoleh sebesar 86% dan kecepatan 38.37 FPS. Pada **(Fang, dkk, 2021)**, YOLOv5 dapat mendeteksi cacat pada permukaan kayu olahan dan kayu cemara, dengan F1-*Score* sebesar 91,7% pada dataset kayu olahan, dan 97,7% pada dataset kayu cemara. Berdasarkan hasil pada penelitian **(Tu, dkk, 2021)** dengan menggunakan YOLOv3 sebagai *baseline* tersebut masih terdapat ruang untuk meningkatkan performa dari sistem dan kinerja YOLOv5 menunjukkan performa yang cukup baik dibandingkan dengan YOLOv3 pada penelitian yang dilakukan oleh **(Fang, dkk, 2021)**.

Model jaringan YOLOv5 **(Liu, dkk, 2020)** **(Jocher, dkk, 2020)** termasuk versi terbaru dari seri arsitektur YOLO. Keakuratan deteksi model jaringan ini tinggi, dan kecepatan inferensinya cepat, dengan kecepatan deteksi tercepat mencapai 140 *frame* per detik. Di sisi lain, ukuran file bobot model jaringan deteksi target YOLOv5 kecil, hampir 90% lebih kecil dari YOLOv4. Hal ini menunjukkan bahwa model YOLOv5 cocok untuk diterapkan ke perangkat tertanam yang menerapkan deteksi waktu nyata. Dengan demikian, keunggulan jaringan YOLOv5 adalah akurasi deteksi yang tinggi, karakteristik yang ringan, dan kecepatan deteksi yang cepat pada saat yang bersamaan **(Yan, dkk, 2021)**. Oleh karena itu, penelitian ini diusulkan untuk meningkatkan performa akurasi dan kecepatan dengan menerapkan teknik *image enhancement* dan beberapa model dari YOLOv5 untuk sistem deteksi cacat pada permukaan kayu pinus dan kayu karet. Teknik *image enhancement* yang digunakan, yaitu *edge filter* dan *Real ESRGAN*. Sedangkan model jaringan YOLOv5 yang digunakan, yaitu: YOLOv5s, YOLOv5m, YOLOv5l, YOLOv5x, YOLOv5-FPN, YOLOv5-BiFPN, YOLOv5s-Transformer, dan YOLOv5-PANet.

2. METODE PENELITIAN

Penelitian ini bertujuan untuk menghasilkan suatu sistem yang dapat mendeteksi cacat pada permukaan kayu. Jenis kayu yang di deteksi, yaitu: kayu pinus dan kayu karet. Penggunaan berbagai model pada YOLOv5 dan *image enhancement* menjadi kontribusi pada penelitian ini. Skema perancangan sistem deteksi cacat pada permukaan kayu dapat dilihat pada Gambar 1.



Gambar 1. Blok Diagram Sistem Deteksi Cacat Permukaan Kayu

2.1 Citra Kayu

Citra kayu yang digunakan pada penelitian ini diperoleh dari dataset publik yang telah dipublikasikan pada penelitian sebelumnya **(Tu, dkk, 2021)**. Terdapat dua jenis citra kayu pada dataset tersebut, yaitu citra kayu pinus dan citra kayu karet yang diambil menggunakan kamera Basler gc120 dan lensa ICOH FL- HC12142M. Kedua jenis citra kayu tersebut berukuran 658×492 piksel dan berwarna RGB dengan format *file* JPG. Namun, pada makalah tersebut tidak menyebutkan pola potongan kayu yang digunakan sebagai *input*. Pada dataset

kayu pinus, terdiri dari dua kelas, yaitu *dead knot* dan *intergrowth knot*. Sedangkan pada dataset kayu karet, terdiri dari empat kelas, yaitu *dead knot*, *intergrowth knot*, *inbark*, dan *growth shake*. Tabel 1 menunjukkan jumlah citra dan pembagian kelas pada kedua jenis kayu (Tu, dkk, 2021). Tabel 2 menunjukkan pembagian data pada simulasi.

Tabel 1. Jumlah Citra Kayu pada Dataset

Jenis Kayu	Jenis Cacat				Total
	<i>Intergrowth Knot</i>	<i>Dead Knot</i>	<i>Inbark</i>	<i>Growth Knot</i>	
Kayu Pinus	416	416	-	-	832
Kayu Karet	389	388	388	388	1553

Tabel 2. Pembagian Data pada Simulasi

Jenis Kayu	Pembagian Data			Total
	Latih (70%)	Validasi (20%)	Uji (10%)	
Kayu Pinus	583	166	83	832
Kayu Karet	1100	302	151	1553

Total data pada kayu pinus adalah sebanyak 832 citra, dan total data pada kayu karet adalah sebanyak 1553 citra. Pembagian data pada simulasi, antara lain: untuk data latih digunakan 70% dari total citra, untuk data validasi digunakan 20% dari total citra, dan untuk data uji digunakan 10% dari total citra.

Gambar 2 merupakan contoh cacat pada citra kayu pinus, sedangkan Gambar 3 merupakan contoh cacat pada citra kayu karet (Tu, dkk, 2021). Lokasi jenis cacat ditandai dengan kotak berwarna. Pada Gambar 2, kotak berwarna hijau menunjukkan jenis cacat *dead knot* dan kotak berwarna kuning menunjukkan jenis cacat *intergrowth knot*. Pada Gambar 3, jenis cacat *dead knot* ditandai dengan kotak pembatas berwarna hijau, *intergrowth knot* ditandai dengan kotak pembatas berwarna kuning, *inbark* ditandai dengan kotak pembatas berwarna biru, dan *growth shake* ditandai dengan kotak berwarna oranye.

2.2 Image Enhancement

Sebelum masuk ke proses *image enhancement*, ukuran citra kayu diubah menjadi 460×460 piksel. Proses *image enhancement* bertujuan untuk meredam *noise*, mempertajam dan mencerahkan gambar, serta untuk mengidentifikasi fitur utama dengan lebih mudah (Shorten & Khoshgoftaar, 2019). Selanjutnya adalah tahapan *image enhancement* sebagaimana yang ditunjukkan blok diagram ada Gambar 1. Terdapat dua jenis *image enhancement* yang dilakukan pada penelitian ini, yaitu *Edge Filter* dan *Real ESRGAN*.


a. Edge Filter

Edge filter bekerja dengan cara meningkatkan kontras piksel pada bagian tepi tertentu, sehingga setelah penerapan *filter* ini dapat terlihat bagian tepinya secara jelas (Shapiro & Stockman, 2001). Secara teknis, *edge filter* dapat diterapkan dengan menggunakan bahasa pemrograman *Python Imaging Library* (<https://pillow.readthedocs.io/en/stable/>) yaitu dengan merancang filter 3×3 untuk mendeteksi bagian tepi.

b. Real Enhanced Super-Resolution Generative Adversarial Networks (Real ESRGAN)


Meskipun banyak upaya telah dilakukan dalam *blind super resolution* untuk memulihkan gambar beresolusi rendah dengan degradasi yang tidak diketahui dan kompleks, namun secara umum masih jauh dari menangani gambar terdegradasi di dunia nyata. *Real ESRGAN* mengembangkan aplikasi restorasi praktis yang dilatih dengan data sintetis murni (Wang, dkk, 2017).

Secara khusus, proses pemodelan degradasi tingkat tinggi diperkenalkan untuk mensimulasikan degradasi dunia nyata yang kompleks dengan lebih baik. Model ini juga mempertimbangkan artefak *ringing* dan *overshoot* yang umum dalam proses sintesis. Selain itu, model tersebut menggunakan diskriminator U-Net dengan normalisasi spektral untuk meningkatkan kemampuan diskriminator dan menstabilkan dinamika pelatihan. Perbandingan ekstensif telah menunjukkan kinerja visual yang superior daripada karya sebelumnya pada berbagai kumpulan data nyata. Model ini juga menyediakan implementasi model (<https://github.com/xinntao/Real-ESRGAN>) yang efisien menggunakan bahasa pemrograman Python dan *deep learning framework pytorch* untuk mensintesis data dengan cepat.



Gambar 2. Cacat pada Citra Kayu Pinus (a) *Dead Knot* (b) *Intergrown Knot* (c) *Dead Knot* dan *Intergrown Knot* (d) *Dead Knot* dan *Intergrown Knot*

Gambar 4 dan 5 menunjukkan perbandingan antara citra kayu orisinal dengan citra kayu yang diberi penambahan *image enhancement edge filter* maupun *Real-ESRGAN*. Citra dengan penambahan *image enhancement* mengurangi *noise* yang terdapat pada citra dan dapat meningkatkan kualitas citra. Secara visual, citra dengan *Real-ESRGAN* memberikan kualitas gambar yang lebih baik dari pada *Edge Filter*. Hasil deteksi untuk ketiga skenario gambar dibahas pada Bagian 3. Kemudian, langkah selanjutnya dilakukan proses pelatihan berbasis CNN menggunakan model YOLOv5.




Gambar 3. Cacat pada Citra Kayu Karet (a) *Dead Knot*, (b) *Intergrown Knot*, (c) *Inbark*, (d) *Growth Shake* (e) *Intergrown Knot* dan *Growth Shake* (f) *Dead Knot* dan *Inbark*


2.3 YOLOv5

Penelitian ini mengusulkan metode berbasis CNN dengan algoritma YOLOv5 untuk mendeteksi cacat pada citra kayu. CNN menggunakan arsitektur tiga dimensi, yaitu lebar (*width*), tinggi (*height*), dan kedalaman (*depth*). CNN terdiri dari *input layer*, *output layer*, serta sejumlah *hidden layer*. Umumnya, pada *hidden layer* terdapat *convolutional layers*, *pooling layers*, *normalization layers*, *ReLU layers*, dan *fully-connected layers* (Suyanto, 2018). YOLOv5

ini merupakan generasi kelima dari YOLO yang dipublikasikan oleh Glenn Jocher, dimana secara arsitektur, YOLOv5 mirip dengan YOLOv4. Seperti yang diperlihatkan pada Gambar 6, YOLOv5 terdiri atas tiga bagian utama, yaitu: *Backbone*, *Neck*, dan *Head* (Fang, dkk, 2021).



Gambar 4. Citra Kayu Pinus (a) Orisinal (b) dengan *Edge Filter*, (c) dengan *Real/ESRGAN*



Gambar 5. Citra Kayu Karet (a) Orisinal, (b) dengan *Edge Filter*, (c) dengan *Real/ESRGAN*

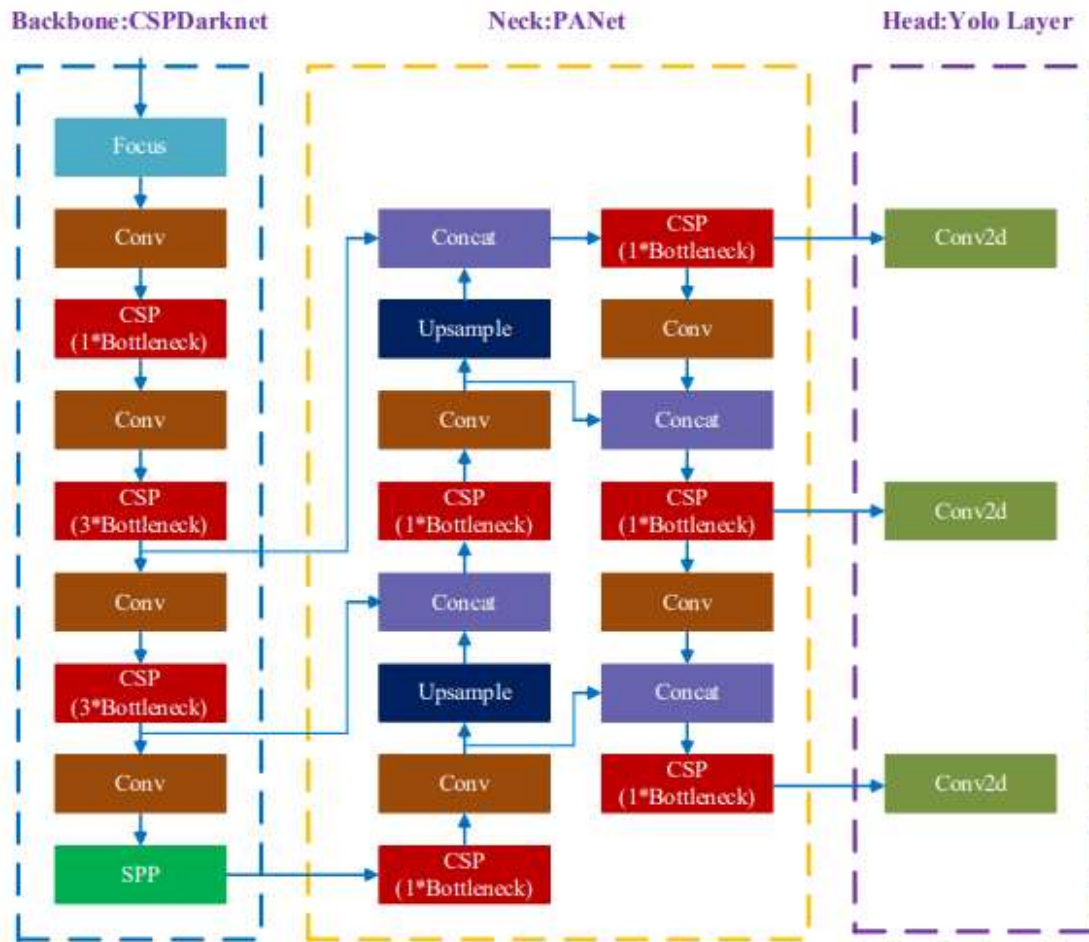
Algoritma YOLOv5 menggunakan aktivasi *leaky RELU* dan *sigmoid*, fungsi optimasi *Adaptive Moment* (Adam) dan *Stochastic Gradient Decent* (SGD), serta fungsi *loss Binary cross-entropy*. Pada YOLOv5, digunakan CSPDarknet sebagai backbone untuk mengekstrak fitur informatif dari gambar *input*. Jika dibandingkan dengan Darknet53 yang digunakan pada YOLOv3, CSPDarknet telah mencapai peningkatan yang cukup besar dalam kecepatan pemrosesan dengan nilai akurasi yang setara (Wang, dkk., 2020). Pada bagian *neck*, YOLOv5 menggunakan *Path Aggregation Network* (PANet) sebagai mekanisme polimerasi parametrik untuk berbagai tingkat detektor (Liu, dkk., 2020). Kisi fitur terhubung ke semua lapisan fitur oleh kumpulan fitur adaptif yang disediakan PANet (Cheng & Zhang, 2020).

2.4 Konfigurasi Struktur

Penelitian ini menggunakan empat model dari YOLOv5 dengan ukuran berbeda, yaitu YOLOv5s (*smallest*), YOLOv5m (*medium*), YOLOv5l (*large*), YOLOv5x (*largest*), serta empat model modifikasi, yaitu YOLOv5-FPN, YOLOv5-BiFPN, YOLOv5-Transformer, dan YOLOv5-PANet.

2.4.1 *Feature Pyramid Network* (FPN)

FPN merupakan ekstraktor fitur yang mengambil sebarang gambar skala tunggal sebagai masukan, dan menampilkan peta fitur berukuran proporsional di berbagai tingkatan secara konvolusional. FPN terdiri dari jalur *bottom-up* dan *top-down*. Jalur *bottom-up* adalah jaringan konvolusional yang biasa digunakan untuk ekstraksi fitur. Saat jalur naik, resolusi spasial berkurang. Semakin banyak struktur tingkat tinggi yang terdeteksi, nilai semantik untuk setiap lapisan meningkat (Lin, dkk, 2017).



Gambar 6. Arsitektur dari Model YOLOv5

2.4.2 Bidirectional Feature Pyramid Network (BiFPN)

BiFPN merupakan jenis jaringan piramida fitur yang memungkinkan fusi fitur multi-skala yang mudah dan cepat (Tan, dkk, 2020).

2.4.3 Vision Transformer (ViT)

ViT merupakan aplikasi transformer dalam domain gambar dengan sedikit modifikasi dalam implementasi untuk menangani modalitas data yang berbeda. Lebih khusus lagi, ViT menggunakan metode yang berbeda untuk tokenisasi dan penyematanan. Namun, arsitektur generiknya tetap sama (Dosovitskiy, dkk, 2020).

2.4.4 Path Aggregation Network (PANet)

PANet merupakan perpanjangan dari Mask-RCNN yang membuat beberapa perbaikan dari pendahulunya. PANet meningkatkan kemampuan Mask-RCNN dengan menambahkan jalur *bottom-up* untuk menambah jalur *top-down* di FPN, menggunakan *Adaptive Feature Pooling* untuk menangkap informasi dari semua level, serta *augmenting mask prediction* dengan lapisan kecil yang terhubung sepenuhnya (Liu, dkk, 2018).

2.5 Spesifikasi Perangkat

Pada penelitian ini, spesifikasi perangkat yang digunakan, yaitu: Processor AMD Ryzen 9 5900HX with Radeon Graphics, RAM 16 GB, dan Google Colab Pro, dengan spesifikasi *Graphic*

Processing Unit (GPU) T4 dan P100, RAM 16 GB. Sedangkan *deep learning framework Pytorch* berbasis bahasa pemrograman *Python* mengikuti dari standar eksperimen YOLOv5 (Jocher, dkk, 2020) yang dijadikan sebagai model *baseline* pada penelitian ini.

2.6 Metrik Evaluasi

Keluaran detektor dibandingkan dengan anotasi manual untuk mengevaluasi kinerja secara kuantitatif. Metrik mAP, F1-Score, precision, dan recall, dihitung menggunakan Persamaan (1) s.d. (4), sedangkan kecepatan deteksi objek dalam satuan *frame per second* (FPS).

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (1)$$

Text

$$F1-Score (\%) = 2 \times \frac{(Precision \times Recall)}{(Precision + Recall)} \times 100 \quad (2)$$

$$Precision (\%) = \frac{TP}{TP + FP} \times 100 \quad (3)$$

$$Recall (\%) = \frac{TP}{TP + FN} \times 100 \quad (4)$$

dimana TP (*true positif*) menunjukkan jumlah cacat yang terdeteksi dengan benar, FP (*false positif*) menunjukkan jumlah cacat yang tidak ada di permukaan kayu, dan FN menunjukkan jumlah cacat yang tidak terdeteksi. *Precision* menunjukkan rasio cacat yang terdeteksi dengan benar dari semua cacat yang terdeteksi. *Recall* merupakan indikasi sensitivitas detektor. *Mean average precision* (mAP) merupakan rata-rata *average precision* (AP) atau ambang batas *Intersection over Union* (IoU) secara keseluruhan untuk semua kelas yang digunakan sebagai parameter evaluasi. Hal ini merupakan standar yang telah digunakan pada aplikasi deteksi obyek secara umum (Redmon, dkk, 2016) dan pada aplikasi deteksi cacat pada permukaan kayu secara khusus (Tu, dkk, 2021). F1-Score menyajikan cara untuk menggabungkan *precision* dan *recall* ke dalam suatu ukuran yang mencakup kedua properti. F1-Score yang lebih tinggi menunjukkan model yang lebih akurat.

3. HASIL DAN PEMBAHASAN

YOLOv5 adalah model yang digunakan untuk mendeteksi obyek secara umum seperti manusia, kendaraan, hewan, dan lain sebagainya. Kajian yang berbeda dalam penelitian ini, YOLOv5 diterapkan pada dataset khusus cacat permukaan kayu dan dikombinasikan dengan blok *enhancement* (Gambar 1) untuk meningkatkan performa. Merujuk kepada hal ini, praproses pelatihan dan pengujian dilakukan mengikuti standar yang diterapkan kepada obyek secara umum. Bagian ini menjelaskan proses pengujian kuantitatif secara rinci yang dibagi kepada tiga skenario dan diakhiri dengan analisa untuk model dengan performa hasil terbaik yang dilengkapi dengan hasil kualitatif atau sampel gambar hasil deteksi dan matrik konfusi dari model tersebut.

3.1 Skenario 1: Pengujian Tanpa Penambahan *Image Enhancement*

Pada bagian ini, dilakukan pengujian tanpa *image enhancement* menggunakan delapan model dari YOLOv5. Tabel 3 merupakan hasil dari pengujian tanpa penggunaan *image enhancement* pada dataset kayu pinus dan kayu karet. Pada hasil pengujian dataset kayu pinus, nilai mAP dan F1-Score tertinggi menggunakan model YOLOv5s, dan untuk nilai FPS tertinggi menggunakan model YOLOv5s-Transformer. Sedangkan pada pengujian dataset kayu karet, nilai mAP dan F1-Score tertinggi menggunakan model YOLOv5l, serta nilai FPS tertinggi menggunakan model YOLOv5s-Transformer.

Tabel 3. Hasil Pengujian Tanpa *Image Enhancement*

Model	Kayu Pinus			Kayu Karet		
	mAP (%)	F1-Score (%)	FPS	mAP (%)	F1-Score (%)	FPS
YOLOv5s	94,3	91,4	30	85,7	83,8	36
YOLOv5m	91,7	89,9	40	87,9	84,7	41
YOLOv5l	92,1	89,3	60	89,2	86,7	61
YOLOv5x	91	88,5	42	87,7	84	56
YOLOv5-FPN	90,8	89,9	58	89,1	85,3	83
YOLOv5-BiFPN	92,5	90,2	55	89,1	84,9	88
YOLOv5s-Transformer	92	87,8	91	86,6	85,1	96
YOLOv5-PANet	91,7	88,2	58	87,2	84,3	51

3.2 Skenario 2: Pengujian Terhadap Penambahan *Edge Filter*

Pada bagian ini, citra masukan diproses dengan menggunakan *image enhancement edge filter* terlebih dahulu sebelum dilakukan proses pelatihan dan pengujian menggunakan model YOLOv5. Tabel 4 merupakan hasil pengujian terhadap penambahan *Edge Filter* menggunakan delapan model dari YOLOv5 pada dataset kayu pinus dan kayu karet.

Tabel 4. Hasil Pengujian dengan Penambahan *Edge Filter*

Model	Kayu Pinus			Kayu Karet		
	mAP (%)	F1-Score (%)	FPS	mAP (%)	F1-Score (%)	FPS
YOLOv5s	93,1	89,6	125	85	81	91
YOLOv5m	89,7	87	104	84,2	82,5	39
YOLOv5l	91,1	89,9	72	86,8	85,4	74
YOLOv5x	91,3	87,4	46	88,6	85,4	49
YOLOv5-FPN	91,6	90,4	61	89,1	85,2	63
YOLOv5-BiFPN	91,9	89,5	75	86,3	83,4	57
YOLOv5s-Transformer	92,1	89,2	85	87,3	83,9	139
YOLOv5-PANet	91,3	89	53	88,7	85,8	56

Berdasarkan Tabel 4, pengujian *image enhancement edge filter* pada dataset kayu pinus didapatkan nilai mAP dan FPS tertinggi menggunakan model YOLOv5s, dan untuk nilai F1-Score tertinggi menggunakan model YOLOv5-FPN. Sedangkan pengujian dataset kayu karet menghasilkan nilai F1-Score tertinggi menggunakan model YOLOv5-PANet, nilai mAP tertinggi menggunakan model YOLOv5-FPN, dan nilai FPS tertinggi menggunakan model YOLOv5s-Transformer.

3.3 Skenario 3: Pengujian Terhadap Penambahan *Real/ESRGAN*

Pada bagian ini, citra masukan diproses dengan menggunakan *image enhancement Real ESRGAN* terlebih dahulu sebelum dilakukan proses pelatihan dan pengujian menggunakan model YOLOv5. Tabel 5 merupakan hasil pengujian terhadap penambahan ESRGAN menggunakan delapan model dari YOLOv5 pada dataset kayu pinus dan kayu karet.

Berdasarkan Tabel 5, pengujian *image enhancement Real ESRGAN* pada dataset kayu pinus, diperoleh nilai F1-Score tertinggi menggunakan model YOLOv5l, nilai mAP dan FPS tertinggi menggunakan model YOLOv5s. Sedangkan untuk dataset kayu karet menghasilkan nilai mAP dan F1-Score tertinggi menggunakan model YOLOv5-Transformer, dan untuk nilai FPS tertinggi menggunakan model YOLOv5s. Dari tiga skenario hasil pengujian diatas diperoleh nilai mAP, F1-Score, dan FPS terbaik.

Tabel 5. Hasil Pengujian dengan Penambahan *Real*/ESRGAN

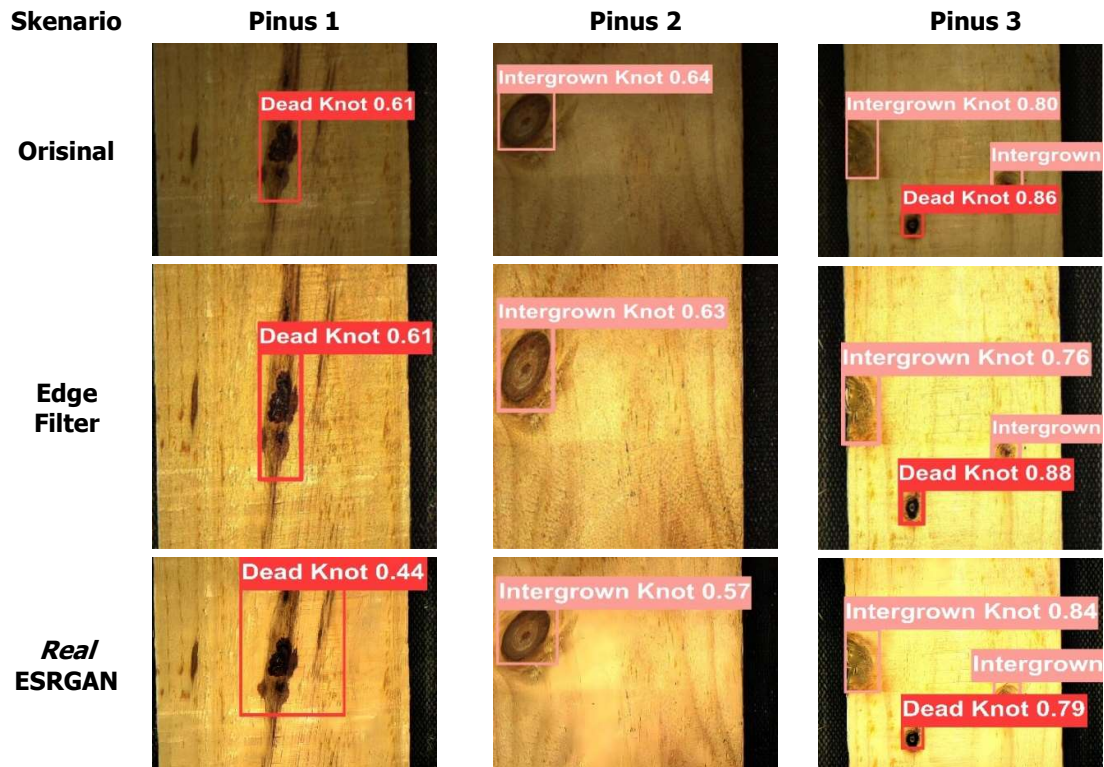
Model	Kayu Pinus			Kayu Karet		
	mAP (%)	F1-Score (%)	FPS	mAP (%)	F1-Score (%)	FPS
YOLOv5s	92,6	88,8	112	88,6	85,4	119
YOLOv5m	89,8	88,7	97	88,6	86,2	65
YOLOv5l	91,5	90,2	79	90,2	87,6	81
YOLOv5x	91,1	87,9	53	90	88,7	53
YOLOv5-FPN	91,1	88,9	34	90,6	86,5	85
YOLOv5-BiFPN	90,5	89,9	42	89,3	86,4	34
YOLOv5s-Transformer	90,3	86,9	86	94,7	91,5	88
YOLOv5-PANet	88,9	86,4	81	88,6	85,9	54

Pada dataset kayu pinus, nilai mAP dan *F1-Score* tertinggi berada pada arsitektur YOLOv5s tanpa penambahan *image enhancement*, yaitu sebesar 94.3% dan 91.4% dengan kecepatan 125 FPS. Hasil yang diperoleh meningkat signifikan dibandingkan penelitian **(Tu, dkk, 2021)** yang hanya menghasilkan mAP diperoleh sebesar 92.29% dan kecepatan 39.81 FPS pada dataset kayu pinus. Pada dataset kayu karet, nilai mAP dan *F1-Score* tertinggi berada pada arsitektur YOLOv5s-Transformer dengan penambahan *Real*/ESRGAN, yaitu sebesar 94,7% dan 91,5% dengan kecepatan 139 FPS. Hasil yang diperoleh meningkat signifikan dibandingkan penelitian **(Tu, dkk, 2021)** yang hanya menghasilkan mAP diperoleh sebesar 86% dan kecepatan 38,37 FPS pada dataset kayu karet.


3.4 Hasil Deteksi Parameter Terbaik

Setelah dilakukan pengujian dari sistem deteksi cacat pada permukaan kayu didapatkan model yang memiliki performa yang konsisten yaitu model YOLOv5s untuk citra kayu pinus dengan dua kategori cacat dan model YOLOv5s-Transformer untuk citra kayu karet yang memiliki kategori cacat lebih kompleks yaitu empat kategori cacat. Selanjutnya dilakukan perbandingan terhadap hasil deteksi pada citra kayu orisinal/ tanpa menggunakan *image enhancement* dan setelah penambahan *image enhancement*, yaitu *edge filter* dan *Real* ESRGAN. Gambar 7 menampilkan perbandingan hasil deteksi pada citra kayu pinus. Citra kayu pinus 1 yang diberi penambahan *Real*/ESRGAN dapat terdeteksi, namun memiliki nilai probabilitas atau akurasi yang lebih rendah yaitu 44%, sedangkan jenis cacat pada citra kayu pinus orisinal dan *edge filter* terdeteksi oleh sistem dengan akurasi 61%. Pada citra kayu pinus 2, jenis cacat pada citra kayu pinus orisinal memiliki nilai akurasi tertinggi yaitu 64% dibandingkan dengan citra kayu pinus dengan penambahan *edge filter* dan *Real*/ESRGAN yang terdeteksi dengan akurasi masing-masing 63% dan 57%. Pada citra kayu pinus 3, jenis cacat pada citra kayu pinus orisinal dapat terdeteksi dengan akurasi 80% dan 86% untuk setiap jenis cacat, namun pada citra kayu pinus dengan penambahan *edge filter* dan dengan penambahan *Real*/ESRGAN terdeteksi oleh sistem dengan akurasi masing-masing 76% dan 88%, dan 79% dan 84%. Hasil ini menunjukkan bahwa YOLOv5s tanpa penambahan *image enhancement* memiliki performa akurasi yang konsisten.

Gambar 8 menampilkan perbandingan hasil deteksi pada citra kayu karet. Citra kayu karet 1 dengan penambahan *image enhancement Real* ESRGAN terdeteksi dengan akurasi tertinggi yaitu 86%, namun pada citra kayu karet lainnya, yaitu orisinal dan dengan penambahan *image enhancement Edge Filter* terdeteksi masing-masing dengan akurasi 80 dan 86%. Pada citra kayu karet 2, jenis cacat pada citra kayu karet yang telah diberi penambahan *Real*/ESRGAN terdeteksi dengan akurasi tertinggi yaitu 82%, namun pada citra kayu karet orisinal dan jenis cacat pada citra kayu karet yang diberi penambahan *Edge Filter* dengan akurasi dibawah delapan puluh persen atau 79% dan 72%.




Gambar 7. Perbandingan Hasil Dateksi pada Citra Kayu Pinus dengan YOLOv5s



Gambar 8. Perbandingan Hasil Dateksi pada Citra Kayu Karet dengan YOLOv5s-Transformer

Pada citra kayu karet 3, pada lokasi cacat yang pertama seperti ditunjukkan pada tabel, jenis cacat pada citra kayu karet orisinal dengan penambahan *Rea/ESRGAN* memiliki akurasi yang sama yaitu 92% dibandingkan dengan pada citra kayu karet dengan penambahan *Edge Filter* yaitu sebesar 85%. Pada lokasi cacat yang kedua, hanya pada citra kayu karet orisinal dengan penambahan *Rea/ESRGAN* yang dapat memprediksi dengan benar jenis cacat dengan akurasi sebesar 82%. Dari analisa ini dapat diambil kesimpulan bahwa YOLOv5s-Transformer dengan penambahan *image enhancement Real ESRGAN* memiliki performa paling baik dibandingkan dengan yang lainnya. Pada Gambar 9 dan Gambar 10 diberikan matrik konfusi dari performa akurasi untuk melengkapi hasil uji performa dari kedua model terbaik pada kayu pinus dan kayu karet.



Gambar 9. Matrik Konfusi YOLOv5s Orisinal pada Citra Kayu Pinus



Gambar 10. Matrik Konfusi YOLOv5s-Transformer dengan Penambahan *Image Enhancement Real ESRGAN* pada Citra Kayu Karet

4. KESIMPULAN

Penelitian ini mengusulkan sistem deteksi cacat pada permukaan kayu pinus dan kayu karet menggunakan model YOLOv5 dan *image enhancement*. Pada citra kayu pinus, model terbaik pada YOLOv5s. Performa akurasi yang dihasilkan juga konsisten. Nilai mAP tertinggi pada dataset kayu pinus yaitu mencapai 94,3% tanpa menggunakan *image enhancement*, namun saat dilakukan penambahan *image enhancement edge filter*, FPS pada dataset ini mengalami peningkatan yang pesat mencapai 125 FPS. Sedangkan pada dataset kayu karet yaitu model terbaik pada YOLOv5s-Transformer. Nilai mAP tertinggi pada dataset kayu karet yang memiliki jenis cacat yang lebih kompleks yaitu mencapai 94,7% dengan penambahan *image enhancement*, yaitu *Real ESRGAN*. Namun FPS tertinggi pada dataset ini mengalami peningkatan yang pesat mencapai 139 FPS saat menggunakan *image enhancement edge filter*. YOLOv5s-Transformer dengan penambahan *image enhancement Real ESRGAN* memiliki performa paling baik dibandingkan dengan citra karet orisinal dan citra karet dengan penambahan *edge filter*.

DAFTAR RUJUKAN

- Abdulfattah, M. E., Novamizanti, L., & Rizal, S. (2021). Super Resolution pada Citra Udara menggunakan Convolutional Neural Network. *ELKOMIKA: Jurnal Teknik Energi Elektrik, Teknik Telekomunikasi, & Teknik Elektronika*, 9(1), 71.
- Bayu, I. G., Novamizanti, L., & Atmaja, R. D. (2015). Deteksi Ada Tidaknya Cacat Pada Kayu Menggunakan Metode Ekstraksi Ciri Statistik. *eProceeding*, 2(1), 1-8.
- Cheng, Z., & Zhang, F. (2020). Flower end-to-end detection based on YOLOv4 using a mobile device. *Wireless Communications and Mobile Computing*.
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., . . . Houlsby, N. (2020). *An image is worth 16x16 words: Transformers for image recognition at scale*. Diambil kembali dari arXiv preprint arXiv:2010.11929.
- Fang, Y., Guo, X., Chen, K., Zhou, Z., & Ye, Q. (2021). Accurate and Automated Detection of Surface Knots on Sawn Timbers Using YOLO-V5 Model. *BioResources*, 16(3).
- Hu, J., Song, W., Zhang, W., Zhao, Y., & Yilmaz, A. (2019). Deep learning for use in lumber classification tasks. *Wood Science and Technology*, 53(2), 505-517.
- Jocher, G., Stoken, A., Borovec, J., Chaurasia, A., & Changyu, L. (2020). *ultralytics/yolov5*. Diambil kembali dari Github Repository, YOLOv5.
- Jung, S. Y., Tsai, Y. H., Chiu, W. Y., & Sun, C. T. (2018). Defect detection on randomly textured surfaces by convolutional neural networks. *2018 IEEE/ASME International Conference on Advanced Intelligent Mechatronics (AIM)*, (pp. 1456-1461). Auckland: IEEE.
- Kurnadi, K., Marsudi, M., & Maulana, Y. (2020). Analisis Pengendalian Produk Cacat Pada Kayu Lapis Menggunakan Sqc (Statistical Quality Control) Pada Pabrik Pt. Wijaya Tri Utama Plywood Industry. *Journal of Industrial Engineering and Operation Management*, 3(2).

- Lathifah, H., Novamizanti, L., & Rizal, a. S. (2020). Fast and Accurate Fish Classification from Underwater Video using You Only Look Once. *Conference Series: Materials Science and Engineering*, 982(1), 012003. IOP Publishing.
- Li, C., Zhang, Y., Tu, W., Jun, C., Liang, H., & Yu, H. (2017). Soft measurement of wood defects based on LDA feature fusion and compressed sensor images. *Journal of Forestry Research*, 28(6), 1285-1292.
- Li, S., Li, D., & Yuan, W. (2019). Wood defect classification based on two-dimensional histogram constituted by LBP and local binary differential excitation pattern. *IEEE Access*, 7, 145829-145842.
- Lin, T. Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2017). Feature pyramid networks for object detection. *Proceedings of the IEEE conference on computer vision and pattern recognition*, (pp. 2117-2125).
- Liu, S., Qi, L., Qin, H., Shi, J., & Jia, J. (2018). Path aggregation network for instance segmentation. *Proceedings of the IEEE conference on computer vision and pattern recognition*, (pp. 8759-8768).
- Liu, Y., Lu, B., Peng, J., & Zhang, Z. (2020). Research on the use of YOLOv5 object detection algorithm in mask wearing recognition. *World Sci. Res. J*, 6, 276–284.
- Mutaqin, D. J., Nurhayani, F. O., & Rahayu, N. H. (2022). Performa Industri Hutan Kayu dan Strategi Pemulihan Pascapandemi Covid-19. *Bappenas Working Papers*, 5(1), 48-62.
- Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 779-788). IEEE.
- Ren, R., Hung, T., & Tan, K. C. (2017). A generic deep-learning-based approach for automated surface inspection. *IEEE transactions on cybernetics*, 48(3), 929-940.
- Shapiro, L. G., & Stockman, G. C. (2001). *Computer vision* (Vol. 3). New Jersey: Prentice Hall.
- Diambil kembali dari Pythonic: pythonic.com
- Shorten, C., & Khoshgoftaar, T. M. (2019). A Survey on Image Data Augmentation for Deep Learning. *Journal of big data*, 6(1), 1-48.
- Suyanto. (2018). *Machine Learning Tingkat Dasar dan Lanjut*. Bandung: Informatika.
- Tan, M., Pang, R., & Le, Q. V. (2020). Efficientdet: Scalable and efficient object detection. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 10781-10790). IEEE.

- Tu, Y., Ling, Z., Guo, S., & Wen, H. (2021). An accurate and real-time surface defects detection method for sawn lumber. *IEEE Transactions on Instrumentation and Measurement*, 70, 1-11.
- Urbanas, A., Raudonis, V., Maskeliūnas, R., & Damaševičius, R. (2019). Automated identification of wood veneer surface defects using faster region-based convolutional neural network with data augmentation and transfer learning. *Applied Sciences*, 9(22), 4898.
- Wananda, P., Novamizanti, L., & Atmaja, a. R. (2018). Sistem Deteksi Cacat Kayu dengan Metode Deteksi Tepi SUSAN dan Ekstraksi Ciri Statistik. *ELKOMIKA: Jurnal Teknik Energi Elektrik, Teknik Telekomunikasi, & Teknik Elektronika*, 6(1), 140.
- Wang, C.-Y., Liao, H.-Y. M., Yeh, I.-H., Wu, Y.-H., Chen, P.-Y., & Hsieh, J.-W. (2020). CSPNet: A New Backbone that can Enhance Learning Capability of CNN. *CVF Conference on Computer Vision and Pattern Recognition*. IEEE.
- Yan, B., Fan, P., Lei, X., Liu, Z., & Yang, F. (2021). A real-time apple targets detection method for picking robot based on improved YOLOv5. *Remote Sensing*, 13(9), 1619.
- Zhang, J., Tang, L., Mingotti, A., Peretto, L., & Wen, H. (2019). Analysis of white noise on power frequency estimation by DFT-based frequency shifting and filtering algorithm. *IEEE Transactions on Instrumentation and Measurement*, 69(7), 4125-4133.